Análise visual de alguns erros de ponto flutuante e ULP em experimentos computacionais

Ribas, E. R. L. D.[1]
D'Afonseca, L. A.[2]
Rocha, L. M.[3]
DM/CEFET-MG, Belo Horizonte, MG

Este trabalho apresenta resultados de estudos realizados em um projeto de iniciação científica cujo objetivo é explorar graficamente alguns efeitos do cálculos realizados com ponto flutuante e das Unidades de Última Posição (Units of Last Place - ULP).

Um sistema de ponto flutuante é a maneira utilizada pelos computadores para representar números reais através de uma notação compacta e eficaz, padronizado pelo IEEE-754. Ele permite escrever números de grandezas diversas utilizando apenas números inteiros. No entanto, essa representação fica limitada ao adequar o número ao sistema adotado, causando erros que podem se acumular em operações sucessivas, produzindo resultados imprecisos ou incorretos.

Um sistema de ponto flutuante pode ser definido da seguinte forma:

$$\mathbb{F}(\beta, t, L, U) = \{0\} \cup \{\pm d_1.d_2d_3 \ldots d_t \times \beta^e : d_1 \neq 0, d_i \in \{0, 1, \ldots, \beta - 1\}, e = L, L+1, \ldots, U\}, \quad (1)$$

onde β é a base, t é o número de dígitos significativos, L é o menor expoente e U é o maior expoente.

O IEEE-754 é um padrão para a representação de números em ponto flutuante em sistemas computacionais, que define formatos de precisão simples (32 bits) e dupla (64 bits). Ele especifica como os números devem ser representados, incluindo a forma como os bits são alocados para o sinal, o expoente e a mantissa. O padrão também define regras para arredondamento, tratamento de casos especiais (como infinito e NaN) e operações aritméticas.

O número representado em ponto flutuante é então calculado como:

$$x = (-1)^s \times (1 + \sum_{i=1}^{t-1} (d_i \times \beta^{-i})) \times \beta^e, \quad (2)$$

onde s é o bit de sinal, d_i são os dígitos significativos e e é o expoente.

O sistema para 64 bits é definido por $\beta = 2$, $t = 53$, $L = -1022$ e $U = 1023$. O sistema para 32 bits é definido por $\beta = 2$, $t = 24$, $L = -126$ e $U = 127$.

No sistema de precisão dupla (64 bits), o número é representado por um bit de sinal, 11 bits para o expoente e 52 bits para a mantissa. No sistema de precisão simples (32 bits), o número é representado por um bit de sinal, 8 bits para o expoente e 23 bits para a mantissa.

$$x = (-1)^s \times (1.f) \times 2^{e - \text{bias}}, \quad (3)$$

Os expoentes e são armazenados em um formato de bias (ou excesso), onde o valor real do expoente é obtido subtraindo-se um valor de bias do valor armazenado. Para o sistema de 64 bits,

[1] enzorochaeleitedinizribas@gmail.com
[2] autor3@email
[3] autor3@email

o bias é 1023, e para o sistema de 32 bits, o bias é 127. Assim o valor real do expoente e é calculado como:

$$e = E - \text{bias}, \tag{4}$$

onde E é o valor armazenado para o expoente.

Por exemplo, considere o número 5.5^{23}. Para representá-lo em ponto flutuante de precisão dupla, primeiro precisamos determinar o expoente binário do número. Isso pode ser feito observando entre quais potências de 2 o valor se encontra.

Calculando uma aproximação do número, temos:

$$5.5^{23} \approx 8.18545 \times 10^{16}. \tag{5}$$

Agora comparamos com potências de 2 próximas:

$$2^{56} = 72057594037927936 \tag{6}$$

$$2^{57} = 144115188075855872 \tag{7}$$

Como

$$2^{56} < 5.5^{23} < 2^{57}, \tag{8}$$

o número pode ser escrito na forma normalizada em base 2:

$$5.5^{23} = (1.f) \times 2^{56}. \tag{9}$$

Assim, o expoente real é

$$e = 56. \tag{10}$$

Em precisão dupla, o expoente armazenado utiliza um *bias* de 1023, portanto:

$$E = e + 1023 = 56 + 1023 = 1079. \tag{11}$$

Agora calculamos a mantissa normalizando o número:

$$1.f = \frac{5.5^{23}}{2^{56}} \tag{12}$$

$$1.f \approx \frac{8.18545 \times 10^{16}}{72057594037927936} \approx 1.135905 \tag{13}$$

Logo,

$$f \approx 0.135905. \tag{14}$$

Portanto, a representação normalizada aproximada do número é:

$$5.5^{23} \approx (-1)^0 \times (1.135905) \times 2^{56}. \tag{15}$$

O erro de ponto flutuante pode ser definido como a diferença entre o valor real e o valor representado em ponto flutuante.

$$Erro = |\bar{x} - x|, \tag{16}$$

A ULP é a menor diferença entre dois números representáveis em ponto flutuante, ou seja, a distância entre um número e o próximo número representável. Pela natureza discreta do sistema

de ponto flutuante, a ULP é uma medida importante para avaliar a precisão dos cálculos realizados com ponto flutuante. A ULP pode ser definida como:

$$ULP(x) = \beta^{e-t+1}, \tag{17}$$

Vamos analisar o número 5.5^{23}.

O número 5.5^{23} é um número muito grande, e quando representado em ponto flutuante, ele pode ser aproximado para um valor próximo a 1.0×10^{16}.

A ULP para o número 5.5^{23} pode ser calculada como:

$$ULP(5.5^{23}) = \beta^{e-t+1}, \tag{18}$$

onde e é o expoente do número 5.5^{23} e t é o número de dígitos significativos.

ERRO 1 **Deve-se indicar/referências a fonte, mesmo quando de autoria própria.** Consulte a Figura 4.

Figura 1: Exemplo de imagem. Fonte: indicar.

ERRO 1 **Deve-se indicar/referências a fonte, mesmo quando de autoria própria.** Consulte a Figura 4.

Figura 2: Exemplo de imagem. Fonte: indicar.

ERRO 1 **Deve-se indicar/referências a fonte, mesmo quando de autoria própria.** Consulte a Figura 4.

Figura 3: Exemplo de imagem. Fonte: indicar.

GRAFICO ULP **Deve-se indicar/referências a fonte, mesmo quando de autoria própria.** Consulte a Figura 4.

Figura 4: Exemplo de imagem. Fonte: indicar.

As referências bibliográficas devem ser inseridas conforme especificado neste padrão, as quais serão automaticamente geradas em ordem alfabética pelo sobrenome do primeiro autor. Este *template* fornece suporte para a inserção de referências bibliográficas com o BibLaTeX. Os dados de cada referência do trabalho devem ser adicionados no arquivo `refs.bib` e a indicação da referência no texto deve ser inserida com o comando `\cite`. Seguem alguns exemplos de referências: livro [**Boldrini**], artigos publicados em periódicos [**Contiero**, **Cuminato**], capítulo de livro [**daSilva**], dissertação de mestrado [**Diniz**], tese de doutorado [**Mallet**], livro publicado dentro de uma série [**Gomes**], trabalho publicado em anais de eventos [**Santos**], *website* e outros [**CNMAC**]. Por padrão, os nomes de todos os autores da obra citada aparecem na bibliografia. Para obras com mais de três autores, é também possível indicar apenas o nome do primeiro autor, seguido da expressão et al. Para implementar essa alternativa, basta remover "`,maxnames=50`" do comando correspondente do código-fonte. Sempre que disponível forneça o DOI, ISBN ou ISSN, conforme o caso.