Análise visual de alguns erros de ponto flutuante e de Units of Last Place em experimentos computacionais

Ribas, E. R. L. D.[1]
D'Afonseca, L. A.[2]
Rocha, L. M.[3]
DM/CEFET-MG, Belo Horizonte, MG

Este trabalho apresenta resultados de estudos realizados em um projeto de iniciação científica cujo objetivo é explorar graficamente alguns efeitos do cálculos realizados com ponto flutuante e das Unidades de Última Posição (Units of Last Place - ULP).

Um Sistema de Ponto Flutuante (SPF) é a técnica utilizada para aproximar números reais pelos computadores através de representações binárias compactas. O padrão definido por [1] formaliza essa arquitetura, alocando bits para sinal, expoente e mantissa em precisões simples (32 bits) e dupla (64 bits), como representado na equação 1. A natureza discreta e finita do conjunto dos reais, essa abordagem introduz erros de representação intrínsecos que, ao se propagarem e acumularem em operações aritméticas sucessivas, podem comprometer severamente a exatidão numérica do sistema.

O número representado em ponto flutuante em computadores é então calculado como:

$$x = (-1)^s \times (1 + \sum_{i=1}^{t-1}(d_i \times \beta^{-i})) \times \beta^e, \tag{1}$$

onde s é o bit de sinal, d_i são os dígitos significativos, e é o expoente, β é a base e t é o número de dígitos significativos. O expoente é armazenado com um viés, ou seja, o valor real do expoente é calculado como $e = E - bias$, onde E é o valor armazenado e $bias$ é um valor constante que depende do formato utilizado. O sistema para 64 bits, utilizado na maioria dos computadores atuais, é definido por $\beta = 2$, $t = 53$, $L = -1022$ e $U = 1023$.

A Unit of Last Place (ULP) é a menor diferença entre dois números representáveis em ponto flutuante, ou seja, a distância entre um número e o próximo número representável [3]. O conjunto de números se torna mais esparso quanto mais distante o número for de zero, aumentando o erro relativo. Dessa forma a ULP se torna uma medida relativa importante para avaliar a precisão dos cálculos realizados com ponto flutuante, podendo ser calculada como:

$$ULP(x) = \beta^{e_x - t + 1}, \tag{2}$$

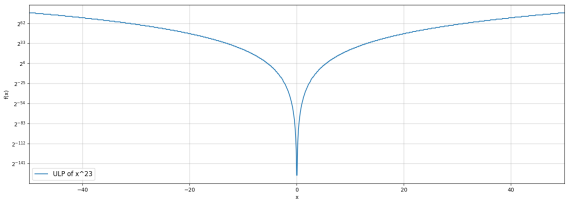

Figura 1: Gráfico da Função $ULP(x^{23})$. Fonte: Autor.

[1] enzorochaeleitedinizribas@gmail.com
[2] autor3@email
[3] autor3@email

Um erro comum em SPF's é o da perda de significância, ou cancelamento catastrófico, que ocorre quando é realizada uma operação com dois números de grandeza muito diferente ou muito próximos, resultando em um valor com menos dígitos significativos do que os números originais, devido ao alinhamento de mantissa. Um exemplo desse comportamento é observado na função $f(x) = x^{10} + l - x^{10}$. Embora para $x \in \mathbb{R}$ o resultado é igual a l, ao efetuarmos os cálculos usando ponto flutuante,o gráfico da figura 2 ilustra que o valor correto é exibido apenas até um certo valor de x.

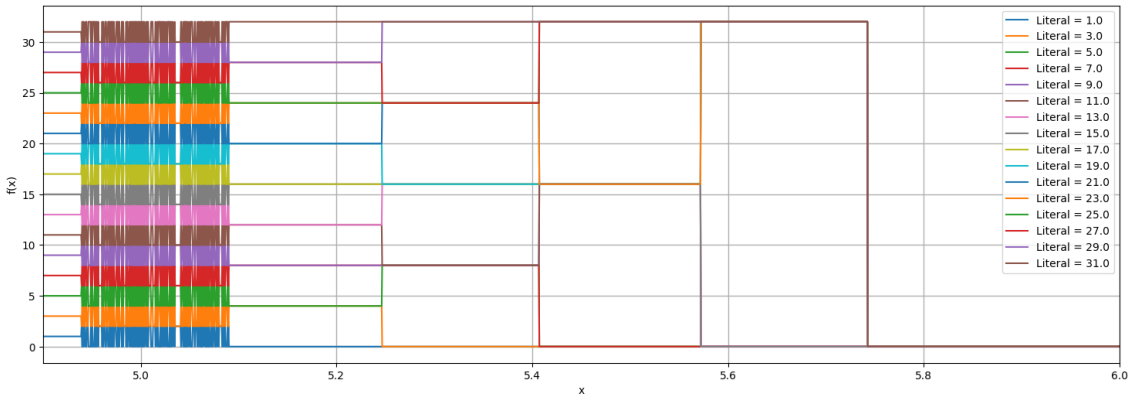

Figura 2: Cancelamento Catastrófico para l variando de 1 a 32 com passo 2. Fonte: Autor.

Essa oscilação é conjecturada a ser diretamente relacionada com a $ULP(x)$ no intervalo em que ela ocorre. Como ilustrado na figura 3, a função $f(x)$ e a $ULP(x)$ se tornam próximas no intervalo em que ocorre a oscilação, sugerindo que o erro relativo da função $f(x)$ é da está associado diretamente a $ULP(x)$ nesse intervalo.

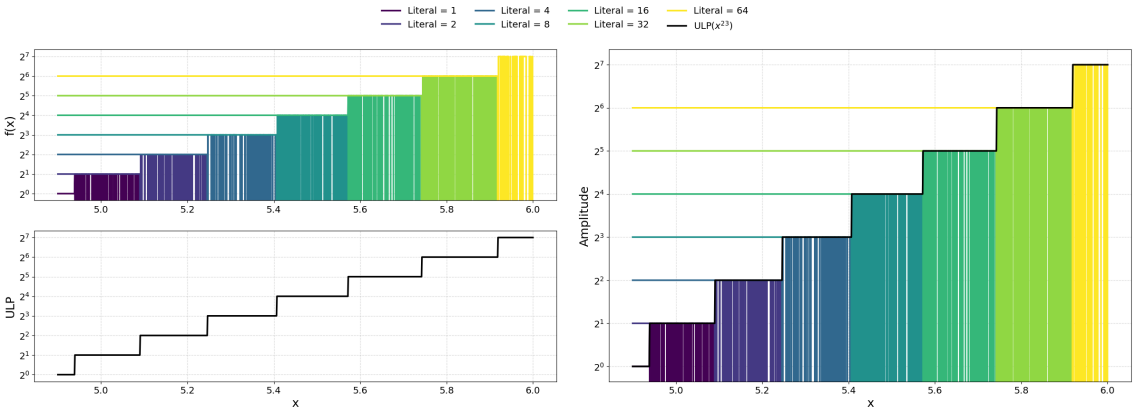

Figura 3: Cancelamento Catastrófico comparado com a ULP. Fonte: Autor.

Referências

[1] **IEEE Standard for Floating-Point Arithmetic**. 2019.

[2] William Kahan. "A logarithm too clever by half". Em: **Unpublished note** (2004).

[3] Jean-Michel Muller. "On the definition of ulp(x)". Em: **CNRS – Laboratoire LIP, projet Arenaire** (2005).