Análise visual de alguns erros de ponto flutuante e ULP em experimentos computacionais

Ribas, E. R. L. D.[1]
D'Afonseca, L. A.[2]
Rocha, L. M.[3]
DM/CEFET-MG, Belo Horizonte, MG

Este trabalho apresenta resultados de estudos realizados em um projeto de iniciação científica cujo objetivo é explorar graficamente alguns efeitos do cálculos realizados com ponto flutuante e das Unidades de Última Posição (Units of Last Place - ULP).

Um sistema de ponto flutuante é a maneira utilizada pelos computadores para representar números reais através de uma notação compacta e eficaz, padronizado pelo IEEE-754. Ele permite escrever números de grandezas diversas utilizando apenas números inteiros. No entanto, essa representação fica limitada ao adequar o número ao sistema adotado, causando erros que podem se acumular em operações sucessivas, produzindo resultados imprecisos ou incorretos.

Um sistema de ponto flutuante pode ser definido da seguinte forma:

$$\mathbb{F}(\beta, t, L, U) = \{0\} \cup \{\pm d_1.d_2d_3 \ldots d_t \times \beta^e : d_1 \neq 0, d_i \in \{0, 1, \ldots, \beta - 1\}, e = L, L+1, \ldots, U\}, \quad (1)$$

onde β é a base, t é o número de dígitos significativos, L é o menor expoente e U é o maior expoente.

O IEEE-754 é um padrão para a representação de números em ponto flutuante em sistemas computacionais, que define formatos de precisão simples (32 bits) e dupla (64 bits). Ele especifica como os números devem ser representados, incluindo a forma como os bits são alocados para o sinal, o expoente e a mantissa. O padrão também define regras para arredondamento, tratamento de casos especiais (como infinito e NaN) e operações aritméticas.

O número representado em ponto flutuante é então calculado como:

$$x = (-1)^s \times (1 + \sum_{i=1}^{t-1} (d_i \times \beta^{-i})) \times \beta^e, \quad (2)$$

onde s é o bit de sinal, d_i são os dígitos significativos e e é o expoente.

O sistema para 64 bits é definido por $\beta = 2$, $t = 53$, $L = -1022$ e $U = 1023$. O sistema para 32 bits é definido por $\beta = 2$, $t = 24$, $L = -126$ e $U = 127$.

A ULP é a menor diferença entre dois números representáveis em ponto flutuante, ou seja, a distância entre um número e o próximo número representável, [**muller2005**]. A natureza discreta do sistema de ponto flutuante junto a limitação de casas decimais da mantissa impactam na precisão de um sistema de ponto flutuante. O conjunto de números se torna mais esparso quanto mais distante o número for de zero. A ULP se torna uma é uma medida relativa importante para avaliar a precisão dos cálculos realizados com ponto flutuante, podendo ser calculada como:

$$ULP(x) = \beta^{e_x - t + 1}, \quad (3)$$

[1] enzorochaeleitedinizribas@gmail.com
[2] autor3@email
[3] autor3@email

O erro de ponto flutuante pode ser definido como a diferença entre o valor real e o valor representado em ponto flutuante.

$$Erro(x) = |\bar{x} - x|\,, \tag{4}$$

Também é possível expressar o erro em termos de ULP, como:

$$\frac{Erro(x)}{ULP(x)} = k, \tag{5}$$

onde k é um número que representa o número de ULPs de erro.

Este trabalho apresenta uma análise visual de alguns erros de ponto flutuante em experimentos computacionais e como a ULP pode ser relacionada a esses erros.

ERRO 1 **Deve-se indicar/referências a fonte, mesmo quando de autoria própria.** Consulte a Figura 1.

Figura 1: Exemplo de imagem. Fonte: indicar.

Vamos analisar o número 5.5^{23}.

O número 5.5^{23} é um número muito grande, e quando representado em ponto flutuante, ele pode ser aproximado para um valor próximo a 1.0×10^{16}.

A ULP para o número 5.5^{23} pode ser calculada como:

$$ULP(5.5^{23}) = \beta^{e-t+1}, \tag{6}$$

onde e é o expoente do número 5.5^{23} e t é o número de dígitos significativos.